

CRISP-DM 프로젝트 분석 및 평가 회의 결과 보고서

1. 회의 개요

회의 목적

- CRISP-DM 기반 프로젝트 수행 방향을 논의한다.
- 데이터 분석 목표 및 수행 방법을 결정한다.
- 제출된 프로젝트를 검토하여 우수 사례와 개선사항을 공유한다.
- 향후 프로젝트 수행 시 적용할 공통 개발 기준을 정리한다.

2. 업무 이해 및 프로젝트 수행 원칙

회의에서는 CRISP-DM(Cross Industry Standard Process for Data Mining) 절차를 기준으로 프로젝트를 수행하기로 합의하였다.

주요 내용은 다음과 같다.

- Business Understanding → Data Understanding → Data Preparation → Modeling → Evaluation → Deployment 절차를 준수한다.
- 분석 목적과 KPI를 사전에 정의한다.
- ETL 과정은 단계별 검증이 가능하도록 설계한다.
- Scheduler 및 Cron 기반 자동화를 고려한다.
- Email 및 Slack 알림 기능을 지원할 수 있도록 설계한다.
- Jinja2를 활용한 자동 보고서(report.md) 생성 기능을 구현한다.
- 프로젝트 구조는 유지보수성과 협업을 고려하여 모듈화한다.
- README에는 프로젝트 목적, 실행 방법, 환경설정 및 의존성을 명확히 기술한다.

3. 데이터 분석 목표 선정

회의 결과 다음 분석 주제를 최종 선정하였다.

선정 주제

AI 도구 활용과 개발자 시장 가치 분석

선정 이유

- AI 기반 개발도구(ChatGPT, GitHub Copilot 등)의 활용이 생산성과 보상 수준에 미치는 영향을 분석할 수 있다.
- 기업의 AI 도입 효과를 정량적으로 검토할 수 있다.
- 연봉, 생산성과 함께 Job Satisfaction 등 정성적 지표도 함께 분석할 수 있다.
- 효과크기(Cohen's d)를 활용하여 통계적 유의성과 실제 효과를 함께 해석할 수 있다.

제외된 주제

인적 자원(학력·직군)과 지역 요인

- 국가 및 지역은 통제가 어려운 변수이다.
- 다양한 교란변수의 영향을 크게 받는다.

근무 형태와 기술 스택

- 기업 정책의 영향을 크게 받는다.
- 새로운 인사이트 도출 가능성이 상대적으로 낮다고 판단하였다.

4. 단계별 논의 결과

Data Understanding

회의에서는 다음 사항을 중요하게 다루었다.

- 대표본에서는 p-value만으로 결과를 해석하지 않는다.
- Cohen's d 등 Effect Size를 함께 제시한다.
- 선택 편향(MNAR) 가능성을 함께 보고한다.

논의 참여

- 정예지
- 김준수

Data Preparation

다음 사항을 적용하기로 하였다.

- 다중 선택 변수는 Binary Encoding으로 변환한다.
- 결측치와 이상치는 도메인 지식을 반영하여 처리한다.
- 데이터 누수(Data Leakage)를 방지하기 위해 Train/Test를 먼저 분리한다.
- Pipeline과 ColumnTransformer를 활용한다.

논의 참여

- 김준수
 - 배은빈
 - 박세웅
 - 배영환
 - 정순욱
-

Modeling

다음 사항을 적용하기로 하였다.

- DummyClassifier를 이용한 Baseline Model과 비교한다.
- Accuracy뿐 아니라 Precision, Recall, F1-score를 함께 평가한다.
- Logistic Regression과 Random Forest를 비교한다.
- Feature Importance는 희귀 범주의 영향을 고려하여 해석한다.

논의 참여

- 정예지
- 김준수

5. 프로젝트 검토 결과

회의에서는 제출된 프로젝트를 검토하고 다음과 같이 의견을 정리하였다.

박세웅

주요 특징

- Pandas와 Polars 비교 분석
- 머신러닝 Pipeline 구현
- Seaborn 및 Plotly 시각화
- Jinja2 기반 Markdown 보고서 생성

개선 의견

- 일부 그래프의 제목과 축 레이블 보완
- 코드 주석 및 설명 추가
- 상관분석 결과에 대한 해석 강화

배영환

주요 특징

- Levene Test
- Cohen's d
- 다중회귀분석
- Polars Lazy Evaluation
- 희귀 범주 제거
- 비즈니스 관점 해석

개선 의견

- Jinja2 기반 자동 보고서 생성 기능 추가 필요
-

배은빈

주요 특징

- 모듈 기반 프로젝트 구조
- Dummy Data 자동 생성
- 다중 머신러닝 모델 비교
- Jinja2 Template 활용
- 운영체제별 한글 폰트 자동 설정

회의 의견

프로젝트 구조와 자동화 구성이 우수하며 재현성과 유지보수성이 뛰어난 사례로 평가하였다.

정예지

주요 특징

- Propensity Score Matching(PSM)
- Confounder 통제
- Slack 및 Email 자동 알림
- Logging 시스템
- Jinja2 기반 자동 보고서 생성
- 다중공선성 처리

회의 의견

인과추론 기법을 적용하여 단순 상관관계를 넘어선 분석을 수행하였으며 실제 운영 환경을 고려한 자동화 구성이 인상적이라는 의견이 제시되었다.

정순욱

주요 특징

- 단계적 회귀모델 비교
- 국가 변수 영향 분석
- 논리적인 분석 흐름
- 비즈니스 관점 해석

개선 의견

자동 보고서는 구현되었으나 Python f-string 대신 Jinja2 기반 구현을 권장하였다.

김준수

주요 특징

- Pytest 기반 테스트 코드
- conftest.py 활용
- 전처리·통계·시각화 테스트
- 리포트 생성 테스트
- 모듈화 구조
- 안정적인 자동화 구현

회의 의견

프로젝트 안정성과 유지보수성을 높인 우수 사례로 평가하였다.

6. 종합 논의

회의에서는 다음 사항이 공통적으로 확인되었다.

데이터 준비

- 대부분 Pandas와 Polars를 함께 활용하였다.
- 결측치 및 이상치 처리가 적절하게 수행되었다.
- Plotly와 Seaborn 시각화를 적절히 활용하였다.

통계 분석

- Cohen's d 활용 사례가 증가하였다.
- 데이터 누수 방지 전략이 적절히 적용되었다.
- Pipeline과 ColumnTransformer 활용이 보편화되었다.
- 회귀분석 및 인과추론 적용 사례가 확인되었다.

자동화

자동화 수준이 전반적으로 향상되었으며 다음 기능들이 공유되었다.

- Markdown 보고서 자동 생성
 - Jinja2 Template 활용
 - Slack 및 Email 알림
 - Logging 시스템
 - 환경변수(.env) 활용
-

7. 향후 개선 방향

회의 결과 다음 사항을 공통 개발 기준으로 적용하기로 하였다.

- CRISP-DM 절차를 지속적으로 준수한다.
 - 데이터 누수를 방지하는 Pipeline 기반 구조를 유지한다.
 - Effect Size를 포함한 통계 해석을 수행한다.
 - 프로젝트 모듈화를 통해 유지보수성을 확보한다.
 - 자동 보고서 생성 기능을 기본 기능으로 포함한다.
 - 테스트 코드 및 운영 자동화를 적극 활용한다.
-

8. 결론

회의 결과, 대부분의 프로젝트는 CRISP-DM 절차를 충실히 반영하고 있었으며 데이터 준비, 통계 분석, 머신러닝, 자동화까지 전반적으로 높은 수준의 구현이 이루어진 것으로 확인되었다.

정예지는 인과추론 기반 분석, 김준수는 테스트 자동화, 배은빈은 모듈화 및 재현성, 배영환은 통계적 해석, 정순욱은 분석 설계, 박세웅은 통합 분석 구현 측면에서 각각 우수 사례를 제시하였다.

향후 프로젝트에서는 이러한 사례를 공통 개발 기준으로 활용하여 분석 품질과 운영 효율성을 함께 향상시키기로 하였다.